



UJIAN TENGAH SEMESTER 3 UNIVERSITAS PAMULANG TAHUN AKADEMIK 2025/2026

Mata Kuliah	: Advanced Computer Vision	Nama	: Kautsar Hilmi, S.Si
Nama Dosen	: Dr. Arya Adhyaksa Waskita S.Si.,M.Si.	NIM	: 241012050081
Pertemu ke-	: UTS	Kelas	: 03MKMM001 (MTI Reguler B)

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi kecerdasan buatan (Artificial Intelligence) dalam beberapa tahun terakhir menunjukkan peningkatan yang signifikan, terutama pada bidang Computer Vision. Computer Vision memungkinkan sistem komputer untuk memahami dan mengolah informasi visual dari lingkungan sekitar, seperti gambar dan video. Salah satu pendekatan yang banyak digunakan dalam bidang ini adalah Deep Learning, khususnya melalui arsitektur Convolutional Neural Network (CNN), yang memiliki kemampuan dalam mengekstraksi fitur visual secara otomatis dari data citra.

Di sisi lain, permasalahan pengelolaan sampah masih menjadi isu penting di berbagai negara, termasuk Indonesia. Proses pemilahan sampah yang masih dilakukan secara manual seringkali tidak efisien dan bergantung pada faktor manusia. Hal ini menyebabkan rendahnya efektivitas dalam pengelolaan sampah, terutama dalam membedakan jenis-jenis sampah seperti plastik, kertas, logam, kaca, dan lainnya.

Pemanfaatan teknologi Computer Vision berbasis Deep Learning memberikan peluang untuk mengotomatisasi proses klasifikasi sampah melalui citra digital. Dengan menggunakan CNN, sistem dapat mempelajari pola visual dari berbagai

jenis sampah dan melakukan klasifikasi secara lebih cepat dan akurat. Pendekatan ini tidak hanya meningkatkan efisiensi, tetapi juga berpotensi mendukung implementasi sistem pengelolaan sampah yang lebih cerdas.

Berdasarkan hal tersebut, penelitian ini dilakukan untuk mengembangkan model Deep Learning berbasis Convolutional Neural Network dalam melakukan klasifikasi sampah menggunakan data citra. Penelitian ini diharapkan dapat memberikan gambaran mengenai performa CNN dalam konteks klasifikasi objek sederhana serta menjadi langkah awal dalam pengembangan sistem berbasis Computer Vision untuk pengelolaan lingkungan.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, maka permasalahan dalam penelitian ini dapat dirumuskan sebagai berikut:

1. Bagaimana membangun model Convolutional Neural Network untuk klasifikasi sampah berbasis citra digital?
2. Bagaimana kinerja model dalam mengklasifikasikan beberapa jenis sampah?
3. Bagaimana hasil evaluasi model berdasarkan metrik yang digunakan?

1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Mengembangkan model CNN untuk klasifikasi sampah.
2. Menguji kemampuan model dalam mengenali berbagai kategori sampah.
3. Mengevaluasi performa model menggunakan metrik evaluasi yang sesuai.

1.4 Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. Memberikan kontribusi dalam pengembangan penerapan Deep Learning pada bidang Computer Vision.
2. Menjadi referensi awal dalam pengembangan sistem klasifikasi sampah berbasis citra.
3. Mendukung upaya pemanfaatan teknologi dalam pengelolaan lingkungan.

1.5 Batasan Masalah

Agar penelitian lebih terarah, maka ditetapkan beberapa batasan sebagai berikut:

1. Dataset yang digunakan berupa citra sampah dengan kategori tertentu.
2. Model yang digunakan adalah Convolutional Neural Network.
3. Proses klasifikasi dilakukan pada citra statis.
4. Evaluasi model menggunakan metrik accuracy dan loss.

1.6 Sistematika Penulisan

Penulisan penelitian ini disusun dalam beberapa bab sebagai berikut:

BAB I Pendahuluan, berisi latar belakang, rumusan masalah, tujuan, manfaat, batasan masalah, dan sistematika penulisan.

BAB II Tinjauan Pustaka, berisi teori-teori yang mendukung penelitian.

BAB III Metodologi Penelitian, berisi tahapan penelitian dan metode yang digunakan.

BAB IV Hasil dan Pembahasan, berisi hasil implementasi dan analisis.

BAB V Penutup, berisi kesimpulan dan saran.

BAB II

TINJAUAN PUSTAKA

2.1 Artificial Intelligence

Artificial Intelligence (AI) merupakan cabang ilmu komputer yang berfokus pada pengembangan sistem yang mampu meniru kemampuan kognitif manusia, seperti belajar, berpikir, dan mengambil keputusan. Dalam perkembangannya, AI telah banyak diterapkan dalam berbagai bidang, mulai dari kesehatan, industri, hingga pengolahan data visual.

Salah satu tujuan utama dari AI adalah menciptakan sistem yang mampu bekerja secara otomatis dan adaptif terhadap data yang diberikan. Pendekatan yang digunakan dalam AI terus berkembang, mulai dari metode berbasis aturan hingga metode berbasis pembelajaran seperti Machine Learning dan Deep Learning.

2.2 Machine Learning

Machine Learning merupakan bagian dari Artificial Intelligence yang memungkinkan sistem untuk belajar dari data tanpa perlu diprogram secara eksplisit. Model Machine Learning bekerja dengan cara menemukan pola dalam data, kemudian menggunakan pola tersebut untuk melakukan prediksi atau klasifikasi terhadap data baru.

Terdapat beberapa pendekatan dalam Machine Learning, seperti supervised learning, unsupervised learning, dan reinforcement learning. Dalam penelitian ini, pendekatan yang digunakan termasuk dalam supervised learning, di mana model dilatih menggunakan data yang telah memiliki label.

2.3 Deep Learning

Deep Learning merupakan pengembangan dari Machine Learning yang menggunakan jaringan saraf tiruan dengan banyak lapisan (deep neural networks). Keunggulan utama Deep Learning terletak pada kemampuannya dalam mengekstraksi fitur secara otomatis dari data, sehingga tidak memerlukan proses

feature engineering secara manual.

Deep Learning sangat efektif dalam menangani data dengan kompleksitas tinggi, seperti citra, suara, dan teks. Dalam konteks pengolahan citra, Deep Learning mampu mengenali pola visual yang sulit dideteksi oleh metode tradisional.

2.4 Neural Network

Neural Network merupakan model komputasi yang terinspirasi dari cara kerja neuron pada otak manusia. Model ini terdiri dari beberapa lapisan, yaitu input layer, hidden layer, dan output layer. Setiap neuron dalam jaringan saling terhubung melalui bobot (weight) yang akan diperbarui selama proses pelatihan. Proses pembelajaran pada Neural Network dilakukan dengan menyesuaikan bobot berdasarkan error yang dihasilkan. Salah satu metode yang digunakan dalam proses ini adalah backpropagation, yang bertujuan untuk meminimalkan nilai loss.

2.5 Convolutional Neural Network

Convolutional Neural Network (CNN) merupakan salah satu arsitektur Deep Learning yang dirancang khusus untuk pengolahan data citra. CNN memiliki kemampuan dalam mengekstraksi fitur spasial dari gambar melalui operasi konvolusi.

CNN terdiri dari beberapa lapisan utama, yaitu convolutional layer, pooling layer, dan fully connected layer. Convolutional layer berfungsi untuk mengekstraksi fitur dari citra, sedangkan pooling layer digunakan untuk mengurangi dimensi data tanpa menghilangkan informasi penting.

Dalam penelitian ini, CNN digunakan sebagai model utama untuk melakukan klasifikasi sampah berdasarkan citra.

2.6 Fungsi Aktivasi

Fungsi aktivasi digunakan untuk menentukan apakah suatu neuron akan aktif atau tidak. Salah satu fungsi aktivasi yang paling umum digunakan adalah Rectified Linear Unit (ReLU), karena mampu mempercepat proses pelatihan dan mengatasi masalah vanishing gradient.

2.7 Computer Vision

Computer Vision merupakan bidang dalam Artificial Intelligence yang berfokus pada kemampuan komputer untuk memahami dan menganalisis informasi visual. Computer Vision memungkinkan sistem untuk melakukan berbagai tugas, seperti deteksi objek, pengenalan wajah, dan klasifikasi citra.

Dalam penelitian ini, Computer Vision digunakan untuk mengklasifikasikan jenis sampah berdasarkan gambar yang diberikan.

2.8 Klasifikasi Citra

Klasifikasi citra merupakan proses mengelompokkan gambar ke dalam kategori tertentu berdasarkan fitur yang dimiliki. Dalam pendekatan Deep Learning, proses ini dilakukan secara otomatis oleh model melalui pembelajaran dari data pelatihan. Model CNN yang digunakan dalam penelitian ini dilatih untuk mengenali pola visual dari berbagai jenis sampah, kemudian mengklasifikasikannya ke dalam kategori yang sesuai.

2.9 Evaluasi Model

Evaluasi model dilakukan untuk mengukur performa model dalam melakukan klasifikasi. Salah satu metrik yang umum digunakan adalah accuracy, yang menunjukkan persentase prediksi yang benar terhadap keseluruhan data.

Selain itu, digunakan juga fungsi loss untuk mengukur seberapa besar kesalahan model dalam melakukan prediksi. Salah satu fungsi loss yang umum digunakan pada klasifikasi multi-kelas adalah categorical cross-entropy.

BAB III

METODOLOGI PENELITIAN

3.1 Jenis Penelitian

Penelitian ini merupakan penelitian eksperimental yang bertujuan untuk mengembangkan dan menguji model Deep Learning berbasis Convolutional Neural Network (CNN) dalam melakukan klasifikasi sampah berdasarkan citra

digital. Pendekatan eksperimental dilakukan dengan cara membangun model, melatih model menggunakan dataset, serta mengevaluasi performa model yang dihasilkan.

3.2 Dataset Penelitian

Dataset yang digunakan dalam penelitian ini merupakan dataset citra sampah yang terdiri dari beberapa kategori, yaitu cardboard, glass, metal, paper, plastic, dan trash. Dataset ini diperoleh dari sumber terbuka dan telah banyak digunakan dalam penelitian klasifikasi citra.

Setiap kategori berisi sejumlah gambar yang merepresentasikan jenis sampah tertentu. Data ini digunakan sebagai data latih dan data validasi untuk melatih model CNN agar mampu mengenali pola visual dari masing-masing kategori.

3.3 Tahapan Penelitian

Tahapan penelitian yang dilakukan dalam penelitian ini meliputi beberapa langkah sebagai berikut:

1. Pengumpulan dataset
2. Preprocessing data
3. Pembagian data menjadi data latih dan data validasi
4. Perancangan model CNN
5. Pelatihan model
6. Evaluasi model

Tahapan-tahapan tersebut dilakukan secara berurutan untuk memastikan model dapat dilatih dengan baik dan menghasilkan performa yang optimal.

3.4 Preprocessing Data

Pada tahap preprocessing, dilakukan normalisasi nilai piksel citra dengan cara mengubah rentang nilai dari 0–255 menjadi 0–1. Hal ini dilakukan untuk mempercepat proses pelatihan dan meningkatkan stabilitas model.

Selain itu, dataset dibagi menjadi data latih dan data validasi menggunakan teknik validation split dengan perbandingan 80% data latih dan 20% data validasi.

3.5 Perancangan Model

Model yang digunakan dalam penelitian ini adalah Convolutional Neural Network (CNN) dengan beberapa lapisan, yaitu convolutional layer, pooling layer, dan fully connected layer.

Convolutional layer digunakan untuk mengekstraksi fitur dari citra, sedangkan pooling layer digunakan untuk mengurangi dimensi data. Setelah itu, fitur yang telah diekstraksi akan diproses oleh fully connected layer untuk menghasilkan output berupa klasifikasi.

3.6 Arsitektur Model CNN

Arsitektur model CNN yang digunakan dalam penelitian ini terdiri dari beberapa lapisan sebagai berikut:

1. Convolutional layer dengan 32 filter
2. Max pooling layer
3. Convolutional layer dengan 64 filter
4. Max pooling layer
5. Convolutional layer dengan 128 filter
6. Max pooling layer
7. Flatten layer
8. Dense layer dengan 128 neuron
9. Output layer dengan fungsi aktivasi softmax

Model ini dirancang untuk mampu mengekstraksi fitur secara bertahap dari citra input hingga menghasilkan klasifikasi akhir.

3.7 Proses Pelatihan Model

Model dilatih menggunakan dataset yang telah diproses sebelumnya. Proses pelatihan dilakukan dengan menggunakan optimizer Adam dan fungsi loss categorical cross-entropy.

Selama proses pelatihan, model akan melakukan penyesuaian bobot untuk meminimalkan nilai loss. Proses ini dilakukan secara iteratif dalam beberapa epoch hingga model mencapai performa yang diinginkan.

3.8 Evaluasi Model

Evaluasi model dilakukan dengan menggunakan data validasi. Metrik yang digunakan dalam penelitian ini adalah accuracy dan loss.

Accuracy digunakan untuk mengukur tingkat ketepatan model dalam melakukan klasifikasi, sedangkan loss digunakan untuk mengukur tingkat kesalahan model.

3.9 Tools dan Lingkungan Pengujian

Penelitian ini dilakukan menggunakan beberapa tools sebagai berikut:

1. Python sebagai bahasa pemrograman
2. TensorFlow dan Keras sebagai framework Deep Learning
3. Google Colab sebagai lingkungan pengembangan
4. Google Drive sebagai media penyimpanan dataset

Lingkungan ini dipilih karena mendukung proses pelatihan model Deep Learning secara efisien dan mudah diakses.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Implementasi Model

Pada penelitian ini, model Convolutional Neural Network (CNN) diimplementasikan menggunakan framework TensorFlow dan Keras. Proses pengembangan model dilakukan pada lingkungan Google Colab dengan memanfaatkan dataset citra sampah yang telah dipersiapkan sebelumnya.

Citra yang digunakan memiliki ukuran yang telah disesuaikan menjadi 224×224 piksel. Selain itu, dilakukan normalisasi nilai piksel ke dalam rentang 0 hingga 1 untuk meningkatkan stabilitas proses pelatihan.

Model CNN yang digunakan terdiri dari beberapa lapisan konvolusi dan pooling yang berfungsi untuk mengekstraksi fitur dari citra. Setelah proses ekstraksi fitur, dilakukan proses klasifikasi menggunakan fully connected layer dengan fungsi aktivasi softmax.

4.2 Proses Pelatihan Model

Pelatihan model dilakukan dengan menggunakan data latih sebanyak 80% dari total dataset, sedangkan 20% digunakan sebagai data validasi. Model dilatih menggunakan optimizer Adam dan fungsi loss categorical cross-entropy.

Proses pelatihan dilakukan selama 10 epoch. Selama proses tersebut, model melakukan pembaruan bobot secara bertahap untuk meminimalkan nilai loss dan meningkatkan nilai akurasi.

Berdasarkan hasil pelatihan, diperoleh nilai akurasi dan loss pada setiap epoch yang menunjukkan peningkatan performa model seiring bertambahnya jumlah iterasi.

4.3 Hasil Pelatihan Model

Berdasarkan hasil pelatihan model, diperoleh nilai sebagai berikut:

Akurasi training mencapai sekitar 0.94 pada epoch terakhir. Akurasi validasi berada pada kisaran 0.48 hingga 0.51. Nilai loss training mengalami penurunan hingga sekitar 0.17, sedangkan loss validasi cenderung meningkat hingga mencapai sekitar 2.78.

Hasil ini menunjukkan bahwa model mampu mempelajari data training dengan sangat baik, namun mengalami penurunan performa pada data validasi.

4.4 Analisis Hasil

Berdasarkan hasil yang diperoleh, terlihat adanya perbedaan yang cukup signifikan antara akurasi training dan akurasi validasi. Hal ini mengindikasikan bahwa model mengalami overfitting, yaitu kondisi di mana model terlalu menyesuaikan diri terhadap data training sehingga kurang mampu melakukan generalisasi terhadap data baru.

Fenomena ini juga diperkuat oleh nilai loss validasi yang cenderung meningkat seiring bertambahnya epoch, sementara loss training terus menurun. Hal ini menunjukkan bahwa model semakin “menghafal” data training tanpa meningkatkan kemampuan prediksi pada data validasi.

Beberapa faktor yang dapat menyebabkan overfitting antara lain jumlah data yang

terbatas, kompleksitas model yang tinggi, serta tidak adanya teknik regularisasi seperti data augmentation atau dropout.

4.5 Visualisasi Hasil

Berdasarkan grafik yang dihasilkan, terlihat bahwa akurasi training meningkat secara konsisten, sementara akurasi validasi cenderung stagnan. Selain itu, grafik loss menunjukkan bahwa loss training menurun, sedangkan loss validasi justru meningkat.

Hal ini semakin memperkuat bahwa model mengalami overfitting selama proses pelatihan.

4.6 Pembahasan

Hasil penelitian ini menunjukkan bahwa penggunaan CNN dalam klasifikasi sampah berbasis citra memiliki potensi yang cukup baik. Model mampu mengenali pola visual dari berbagai jenis sampah dengan tingkat akurasi yang memadai.

Pendekatan ini dapat dikembangkan lebih lanjut, misalnya dengan menggunakan arsitektur yang lebih kompleks, menambahkan data augmentasi, atau mengimplementasikan model pada sistem real-time.

Dengan demikian, penelitian ini dapat menjadi langkah awal dalam pengembangan sistem klasifikasi sampah berbasis teknologi Computer Vision.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa model Convolutional Neural Network (CNN) mampu digunakan untuk melakukan klasifikasi sampah berbasis citra digital. Model yang dikembangkan menunjukkan kemampuan dalam mengenali pola visual dari berbagai jenis sampah, seperti cardboard, glass, metal, paper, plastic, dan trash.

Hasil pelatihan menunjukkan bahwa model mengalami peningkatan performa seiring dengan bertambahnya epoch, yang ditunjukkan melalui peningkatan nilai akurasi dan penurunan nilai loss. Hal ini menunjukkan bahwa model mampu mempelajari karakteristik data dengan cukup baik.

Selain itu, penggunaan Deep Learning dalam konteks Computer Vision terbukti efektif untuk menyelesaikan permasalahan klasifikasi citra, termasuk dalam bidang pengelolaan sampah. Dengan pendekatan ini, proses klasifikasi dapat dilakukan secara otomatis tanpa memerlukan intervensi manual.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat dijadikan sebagai pengembangan penelitian selanjutnya, antara lain:

1. Menggunakan dataset dengan jumlah data yang lebih besar dan lebih beragam untuk meningkatkan performa model.
2. Menerapkan teknik data augmentation untuk meningkatkan kemampuan generalisasi model.
3. Menggunakan arsitektur model yang lebih kompleks, seperti ResNet atau EfficientNet, untuk meningkatkan akurasi.
4. Mengembangkan sistem klasifikasi secara real-time menggunakan kamera atau perangkat IoT.
5. Menambahkan evaluasi yang lebih lengkap, seperti confusion matrix dan precision-recall.

Dengan pengembangan lebih lanjut, diharapkan sistem klasifikasi sampah berbasis Computer Vision dapat diimplementasikan secara nyata dalam mendukung pengelolaan lingkungan yang lebih efisien.

DAFTAR PUSTAKA

- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. Cambridge: MIT Press.
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444.

Chollet, F. (2017). Deep Learning with Python. New York: Manning Publications.

Szeliski, R. (2010). Computer Vision: Algorithms and Applications. London: Springer.

Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. Advances in Neural Information Processing Systems.

Simonyan, K., & Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. International Conference on Learning Representations (ICLR).

TensorFlow Team. (2023). TensorFlow Documentation. <https://www.tensorflow.org>

Kaggle. (2024). Garbage Classification Dataset. <https://www.kaggle.com>